



常用知识点回顾

汇报人 | XXX

指导老师 | XXX



目录 CONTENTS

- 1、连续函数的导数
- 2、方向导数与梯度
- 3、矩阵运算及性质
- 4、线性空间、内积与范数
- 5、泰勒公式
- 6、离散情形下函数的导数
- 7、凸集、凸函数、利普希茨函数
- 8、优化问题、线性规划、凸优化问题



1、连续函数的导数

1.1、单变量函数的导数

一阶导数定义：设函数 $y = f(x)$ 在点 x_0 的某邻域内有定义，

若极限

$$\lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

存在，则称函数 f 在点 x_0 可导，记作 $f'(x_0)$.

计算： 基本初等函数导数公式

四则运算和复合函数的导数

二阶导数定义：若函数 f 的导函数 f' 在点 x_0 可导，

则称 f' 在点 x_0 的导数为 f 在点 x_0 的二阶导数，

记作 $f''(x_0)$, 即

$$\lim_{x \rightarrow x_0} \frac{f'(x) - f'(x_0)}{x - x_0} = f''(x_0),$$

一般，我们可由 f 的 $n-1$ 阶导函数定义 n 阶导数

函数乘积 n 阶导数计算的莱布尼茨公式

$$(uv)^n = \sum_{k=0}^n C_n^k u^{(n-k)} v^{(k)}$$



1、连续函数的导数

1.2、多变量函数的偏导数

定义：设函数 $z = f(x, y)$, $(x, y) \in D$. 若 $(x_0, y_0) \in D$, 且 $f(x, y)$ 在 x_0 的某邻域内有定义, 则当极限

$$\lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x, y_0) - f(x_0, y_0)}{\Delta x}$$

存在时, 称这个极限为函数 f 在点 (x_0, y_0) 关于 x 的偏导数, 记作 $f_x(x_0, y_0)$ 或 $\frac{\partial z}{\partial x} \Big|_{(x_0, y_0)}$

计算：复合函数的链式法则

若函数 $z = f(x, y), x = \varphi(s, t), y = \psi(s, t)$, 则

$$\begin{aligned} \frac{\partial z}{\partial s} \Big|_{(s, t)} &= \frac{\partial z}{\partial x} \Big|_{(x, y)} \frac{\partial x}{\partial s} \Big|_{(s, t)} + \frac{\partial z}{\partial y} \Big|_{(x, y)} \frac{\partial y}{\partial s} \Big|_{(s, t)}, \\ \frac{\partial z}{\partial t} \Big|_{(s, t)} &= \frac{\partial z}{\partial x} \Big|_{(x, y)} \frac{\partial x}{\partial t} \Big|_{(s, t)} + \frac{\partial z}{\partial y} \Big|_{(x, y)} \frac{\partial y}{\partial t} \Big|_{(s, t)}. \end{aligned}$$



1、连续函数的导数

1.3、多变量函数的高阶偏导数计算

由于 $z = f(x, y)$ 的偏导数 $f_x(x, y)$, $f_y(x, y)$,仍是自变量 x 与 y 的函数, 如果它们关于 x 与 y 的偏导数也存在, 则称函数 f 具有二阶偏导数, 二元函数的二阶偏导数有以下四种情形:

$$\frac{\partial}{\partial x} \left(\frac{\partial z}{\partial x} \right) = \frac{\partial^2 z}{\partial x^2} = f_{xx}(x, y),$$

对 n 元函数: $y = f(x_1, x_2, \dots, x_n)$

$$\frac{\partial}{\partial y} \left(\frac{\partial z}{\partial x} \right) = \frac{\partial^2 z}{\partial x \partial y} = f_{xy}(x, y),$$

1阶导数为梯度 $\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$

$$\frac{\partial}{\partial x} \left(\frac{\partial z}{\partial y} \right) = \frac{\partial^2 z}{\partial y \partial x} = f_{yx}(x, y),$$

$$\frac{\partial}{\partial y} \left(\frac{\partial z}{\partial y} \right) = \frac{\partial^2 z}{\partial y^2} = f_{yy}(x, y).$$

2阶导数为黑塞矩阵 $\nabla^2 f = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$



2、方向导数、梯度、散度

2.1、方向导数

定义：设三元函数 f 在点 $P_0(x_0, y_0, z_0)$ 的某邻域 $U(P_0) \subset \mathbb{R}^3$ 有定义， l 为从点 P_0 出发的射线， $P(x, y, z)$ 为 l 上且含于 $U(P_0)$ 内的任一点，以 ρ 表示 P 与 P_0 两点间的距离.若极限

$$\lim_{\rho \rightarrow 0^+} \frac{f(P) - f(P_0)}{\rho} = \lim_{\rho \rightarrow 0^+} \frac{\Delta_l f}{\rho}$$

存在，则称此极限为函数 f 在点 P_0 沿方向 l 的方向导数.记作： $\frac{\partial f}{\partial l} \big|_{p_0}, f_l(p_0)$ 或 $f_l(x_0, y_0, z_0)$

定理：若函数 f 在点 $P_0(x_0, y_0, z_0)$ 可微，则 f 在点 P_0 沿任一方向 l 的方向数都存在，且

$$f_l(p_0) = f_x(p_0) \cos \alpha + f_y(p_0) \cos \beta + f_z(p_0) \cos \gamma$$



2、方向导数、梯度、散度

2.2、梯度定义

定义：若 $f(x, y, z)$ 在点 $P_0(x_0, y_0, z_0)$ 的存在对所有自变量的偏导数，则称向量 $(f_x(P_0), f_y(P_0), f_z(P_0))$ 为函数 f 在点 P_0 的梯度，记作

$$\text{grad} f = (f_x(P_0), f_y(P_0), f_z(P_0))$$

引入梯度算子

$$\nabla = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y}, \frac{\partial}{\partial z} \right)$$

梯度可以写作

$$\text{grad} f = \nabla f$$

向量 $\text{grad} f$ 的长度（模）为 $|\text{grad} f| = \sqrt{f_x(P_0)^2 + f_y(P_0)^2 + f_z(P_0)^2}$

$$1)、\nabla(u + c) = \nabla u$$

$$2)、\nabla(\alpha u + \beta v) = \alpha \nabla u + \beta \nabla v$$

$$3)、\nabla(uv) = u \nabla v + v \nabla u$$

$$4)、\nabla f(u) = f'(u) \nabla u$$



2、方向导数、梯度、散度

2.3、梯度的含义

f 可微时, 记 $l_0 = (\cos\alpha, \cos\beta, \cos\gamma)$ 为 l 方向

的单位方向向量, 则方向导数可写为

$$f_l(p_0) = \nabla f(p_0) \cdot l_0 = |\nabla f(p_0)| \cos \theta$$

θ 是梯度向量 $\nabla f(p_0)$ 与 l_0 的夹角

可知, 当 $\theta = 0$ 时, $f_l(p_0)$ 取得最大值 $|\nabla f(p_0)|$,

即 f 在点 P_0 的梯度方向是 f 的值增长最快的方向,

沿这一方向的变化率就是梯度的模.

而梯度的反方向就是 f 的值减小最快的方向

2.4、散度

设空间 V 上的向量函数

$$A(x, y, z) = (P(x, y, z), Q(x, y, z), R(x, y, z))$$

A 在点 $(x, y, z) \in V$ 的散度

$$\operatorname{div} A = \frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z}$$

于是

$$\operatorname{div} A = \nabla \cdot A$$

拉普拉斯算子

$$\Delta = \nabla \cdot \nabla = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} + \frac{\partial^2}{\partial z^2}$$



3、矩阵运算及性质

3.1、基本运算

1)、 $C = A \pm B, c_{ij} = a_{ij} \pm b_{ij}, (A, B, C \in R^{m \times n})$

2)、 $C = \alpha A, c_{ij} = \alpha a_{ij}$

3)、 $C = A * B, c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}, (A \in R^{m \times n}, B \in R^{n \times p}, C \in R^{m \times p})$

$$C = A . * B, c_{ij} = a_{ij} \cdot b_{ij}, (A, B, C \in R^{m \times n})$$

4)、 转置矩阵 $C = A^T, c_{ij} = a_{ji}, (A \in R^{m \times n}, C \in R^{n \times m})$

$$\text{有 } (AB)^T = B^T A^T.$$

5)、 单位矩阵 $I = (e_1, e_2, \dots, e_n) \in R^{n \times n},$

6)、 非奇异矩阵 设 $A \in R^{n \times n}, B \in R^{n \times n}$, 若 $AB = BA = I$, 则称 B 是 A 的逆矩阵, 记 A^{-1}

$$\text{有 } (A^{-1})^T = (A^T)^{-1}. \text{如果 } A^{-1} \text{ 存在, 则称 } A \text{ 为非奇异矩阵.}$$

$$\text{如果 } A, B \in R^{n \times n} \text{ 为非奇异矩阵, 则 } (AB)^{-1} = B^{-1} A^{-1}.$$



3、矩阵运算及性质

3.2、矩阵的行列式与特征值

1. 矩阵的行列式, $A \in R^{n \times n}$, $\det(A) = \sum_{j=1}^n a_{ij} A_{ij}, i = 1, 2, \dots, n.$

1)、 $\det(AB) = \det(A) \det(B), A, B \in R^{n \times n}$

2)、 $\det(A^T) = \det(A), A \in R^{n \times n}$

3)、 $\det(cA) = c^n \det(A), A \in R^{n \times n}$

4)、 $\det(A) \neq 0 \Leftrightarrow A$ 为非奇异矩阵, $A \in R^{n \times n}$

2. 矩阵的特征值 $A = (a_{ij}) \in R^{n \times n}$, 若存在数 λ 和

非零向量 $x = (x_1, x_2, \dots, x_n)^T \in R^n$, 使

$$Ax = \lambda x$$

则称 λ 为 A 的特征值, x 为 A 对应 λ 的特征向量.

3. 矩阵 A 的特征多项式 $p(\lambda) = \det(\lambda I - A)$

若 $A = (a_{ij}) \in R^{n \times n}$ 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$. 则

$$\det(A) = \lambda_1 \lambda_2 \cdots \lambda_n,$$

$$A \text{ 的迹 } trA = \sum_{i=1}^n a_{ii} = \sum_{i=1}^n \lambda_i$$



4.1、线性空间

\mathbb{F} 是一个域, 设 V 是一个非空集合. 在集合 V 的元素之间定义了一种代数运算, 叫做加法; 这就是说, 给出了一个法则, 对于 V 中任意两个元素 α 与 β , 在 V 中都有唯一的一个元素 γ 与它们对应, 称为 α 与 β 的和, 记为 $\gamma = \alpha + \beta$. 在域 \mathbb{F} 与集合 V 的元素之间还定义了一种运算, 叫做数量乘法; 这就是说, 对于域 \mathbb{F} 中任一数 k 与 V 中任一元素 α , 在 V 中都有唯一的一个元素 δ 与它们对应, 称为 k 与 α 的数量乘积, 记为 $\delta = k\alpha$. 如果加法与数量乘法满足下述规则, 那么 V 称为域 \mathbb{F} 上的线性空间.

加法满足下面四条规则:

- 1) $\alpha + \beta = \beta + \alpha$;
- 2) $(\alpha + \beta) + \gamma = \alpha + (\beta + \gamma)$;
- 3) 在 V 中有一个元素 0 , 对于 V 中任一元素 α 都有 $\alpha + 0 = \alpha$;
- 4) 对于 V 中每一个元素 α , 都有 V 中的向量 β , 使得 $\alpha + \beta = 0$.

数量乘法满足下面两条规则:

- 5) $1\alpha = \alpha$;
- 6) $k(l\alpha) = (kl)\alpha$.

数量乘法与加法满足下面两条规则:

- 7) $(k + l)\alpha = k\alpha + l\alpha$;
- 8) $k(\alpha + \beta) = k\alpha + k\beta$.



4、线性空间、内积与范数

4.2、内积

定义 设 X 是数域 K 上的线性空间, 对 $\forall u, v \in X$, 有 K 中一个数与之对应, 记为 (u, v) , 满足以下条件:

1)、 $(u, v) = \overline{(v, u)}$

2)、 $(\alpha u, v) = \alpha(u, v)$

3)、 $(u + v, w) = (u, w) + (v, w)$

4)、 $(u, u) \geq 0$, 当且仅当 $u = 0$ 时, $(u, u) = 0$

则称 (u, v) 为 X 上 u 和 v 的内积.

例1、设 $x, y \in R^n, x = (x_1, x_2, \dots, x_n)^T, y = (y_1, y_2, \dots, y_n)^T$,

例2、 $C[a, b]$ 上带权内积

则

$$(x, y) = x^T y = \sum_{i=1}^n x_i y_i$$

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx$$



4、线性空间、内积与范数

4.3、范数

定义 设 S 为线性空间, $x \in S$, 若存在唯一实数 $\| \cdot \|$, 满足条件:

1) 、 $\| x \| \geq 0$, 当且仅当 $x = 0$ 时, $\| x \| = 0$; (正定性)

2) 、 $\| \alpha x \| = |\alpha| \cdot \| x \|$, $\alpha \in R$; (齐次性)

3) 、 $\| x + y \| \leq \| x \| + \| y \|$, $x, y \in S$. (三角不等式)

则称 $\| \cdot \|$ 为线性空间上 S 的范数, S 与 $\| \cdot \|$ 一起称为赋范线性空间

例1、对 R^n 上的向量 $x = (x_1, x_2, \dots, x_n)^T$, 常用的范数有:

$$\infty\text{-范数} \quad \| x \|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

$$1\text{-范数} \quad \| x \|_1 = \sum_{i=1}^n |x_i|$$

$$2\text{-范数} \quad \| x \|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}}$$

例2、对连续函数空间 $C[a, b]$, $f \in C[a, b]$

$$\infty\text{-范数} \quad \| f \|_{\infty} = \max_{a \leq x \leq b} |f(x)|$$

$$1\text{-范数} \quad \| f \|_1 = \int_a^b |f(x)| dx$$

$$2\text{-范数} \quad \| f \|_2 = \left(\int_a^b f^2(x) dx \right)^{\frac{1}{2}}$$



4、线性空间、内积与范数

4.4、矩阵的范数

定义 如果矩阵 $A \in R^{n \times n}$ 的某个非负实值函数 $N(A) = \|A\|$ 满足条件:

- 1) $\|A\| \geq 0$, 当且仅当 $A = 0$ 时, $\|A\| = 0$; (正定性)
- 2) $\|cA\| = |c| \cdot \|A\|, c \in R$; (齐次性)
- 3) $\|A + B\| \leq \|A\| + \|B\|$ (三角不等式)
- 4) $\|AB\| \leq \|A\| \|B\|$.

则称 $N(A)$ 是 $R^{n \times n}$ 上的一个矩阵范数

常用矩阵范数: 行-范数 $\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$

列-范数 $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$

2-范数 $\|A\|_2 = (\lambda_{\max}(A^T A))^{\frac{1}{2}}$

把矩阵 A 看作 mn 维向量

$$\|A\| = \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{\frac{1}{2}}$$



5、泰勒公式

5.1、一元函数的泰勒公式

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n + R_n(x) \quad (1)$$

其中余项 $R_n(x)$ 有三种形式, 分别为**积分余项**

$$R_n(x) = \frac{1}{n!} \int_{x_0}^x f^{(n+1)}(t)(x - t)^n dt \quad (2)$$

Lagrange余项

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}(x - x_0)^{n+1}, \quad \xi \in (x_0, x) \quad (3)$$

和**Peano余项**

$$R_n(x) = o((x - x_0)^n) \quad (4)$$



第二部分

研 究 内 容

RESEARCH CONTENTS

6、离散情形下导数的计算

6.1、数字图像获取——取样和量化

一副连续的图像 $f(x, y)$ ，经取样和量化转换为一副数字图像

取样：对图像空间坐标离散化

量化：对图像幅度离散化

6.2、数字图像表示

计算机中一般用二维矩阵存储一副数字图像

$$f(x, y) = \begin{pmatrix} f(0, 0) & f(0, 1) & \cdots & f(0, N-1) \\ f(1, 0) & f(1, 1) & \cdots & f(1, N-1) \\ \vdots & \vdots & \ddots & \vdots \\ f(M-1, 0) & f(M-1, 1) & \cdots & f(M-1, N-1) \end{pmatrix}$$

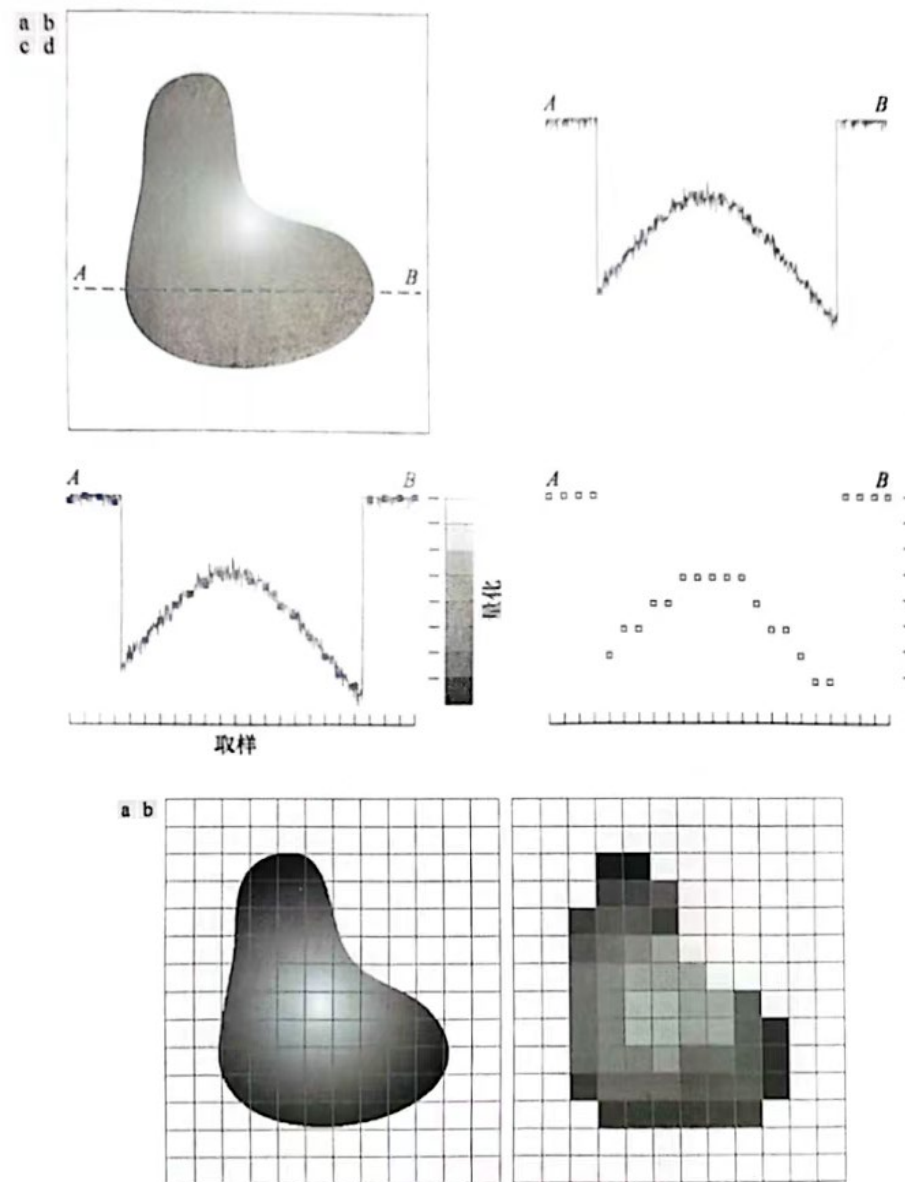



图 2.17 (a)投影到传感器阵列上的连续图像；(b)图像取样和量化后的结果



6、离散情形下导数的计算

6.3、单变量函数导数的计算

设函数 $f(x)$ 定义在 $[0, M]$ 上，对 $[0, M]$ 离散



则一阶向前差分

$$f'(x_i) = \frac{f(x_{i+1}) - f(x_i)}{\Delta x}, i = 0, 1, \dots, N-1.$$

二阶向前差分

$$f''(x_i) = \frac{f(x_{i+1}) - 2f(x_i) + f(x_{i-1}))}{(\Delta x)^2}, i = 1, \dots, N-1.$$



6、离散情形下导数的计算

6.3、二元函数导数的计算


设函数 $f(x, y)$ 定义在 $[0, M] \times [0, N]$ 上, 对 $[0, M] \times [0, N]$ 离散

则一阶向前差分

$$\frac{\partial f}{\partial x}(x_i, y_j) = \frac{f(x_{i+1}, y_j) - f(x_i, y_j)}{\Delta x}, \quad i = 0, 1, \dots, M-1, \quad j = 0, 1, \dots, N-1.$$

二阶向前差分

$$\frac{\partial^2 f}{\partial x^2}(x_i, y_j) = \frac{f(x_{i+1}, y_j) - 2f(x_i, y_j) + f(x_{i-1}, y_j)}{(\Delta x)^2}, \quad i = 1, \dots, M-1, \quad j = 1, \dots, N-1.$$




7、凸集、凸函数、利普希茨函数

7.1、凸集

定义：如果集合 C 中任意两点的连线线段仍在 C 中，
则称 C 是凸集

即对任意 $x_1, x_2 \in C, \theta \in [0, 1]$,

有 $\theta x_1 + (1 - \theta)x_2 \in C$



7.2、凸函数

定义：定义在凸集 C 上的函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数，
如果满足对任意 $x, y \in C, \theta \in [0, 1]$, 有

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

几何意义： f 图像上任意两点的弦位于函数图像上方

当 f 可微时，凸函数的等价定义

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

强凸函数：上述不等式变为严格不等式， $\theta \in (0, 1)$ 时.

μ -强凸函数：

$$f(x) = h(x) + \frac{\mu}{2} \|x - x_0\|^2$$

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{\mu}{2} \|y - x\|^2$$



7、凸集、凸函数、利普希茨函数

7.3、利普希茨函数

定义：如果函数 f 满足利普希茨条件：

存在非负常数 L 使得对任意的 $x, y \in C$ ，都有

$$\|\nabla^p f(x) - \nabla^p f(y)\| \leq L \|x - y\| \quad \forall x, y \in C. \quad (1)$$

则称 f 是利普希茨函数.

$$p = 0, \text{ 时, } |f(x) - f(y)| \leq L |x - y|$$

性质：

1、有界性（变化率有限）

2、局部光滑性（存在任意阶导数）

3、一致连续性

用 $C_L^p(C)$ 表示满足 (1) 的函数族，则有以下性质

Lipschitz函数的性质（在凸集 C 上）

lemma 1.2.2. (用 $\nabla^2 f(x)$ 表示的 $C_L^1(C)$ 的等价条件)

$$f \in C_L^1(C) \iff \|\nabla^2 f(x)\| \leq L \iff -LI_n \leq \nabla^2 f(x) \leq LI_n, \quad \forall x \in C \quad (4)$$

lemma 1.2.3. 若 $f \in C_L^1(C)$ ，则 $\forall x, y \in C$ 有

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2 \quad (5)$$

lemma 1.2.4. 若 $f \in C_M^2(C)$ ，则 $\forall x, y \in C$ 有

$$\|\nabla f(y) - \nabla f(x) - \langle \nabla^2 f(x), y - x \rangle\| \leq \frac{M}{2} \|y - x\|^2 \quad (6.1)$$

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle - \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle| \leq \frac{M}{6} \|y - x\|^3 \quad (6.2)$$

Cor 1.2.2. 若 $f \in C_M^2(C)$ ，则 $\forall x, y \in C$ 有

$$\begin{aligned} \nabla^2 f(x) - M\|y - x\|I_n &\leq \nabla^2 f(y) \leq \nabla^2 f(x) + M\|y - x\|I_n \\ -M\|y - x\|I_n &\leq \nabla^2 f(y) - \nabla^2 f(x) \leq M\|y - x\|I_n \end{aligned} \quad (6.3)$$



8、优化问题、线性规划、凸优化

8.1、数学优化问题

常见形式:


$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, \quad i = 1, 2, \dots, s, \\ & h_j(x) = 0, \quad j = 1, 2, \dots, t. \end{aligned}$$

$f(x)$: 目标函数,

决策变量,

约束条件,

可行解, 可行域



局部最优解, 全局最优解



8、优化问题、线性规划、凸优化

8.2、线性规划标准型

【例1-12】将下列线性规划化为标准型

$$\text{Max } Z = -x_1 + x_2 - 3x_3$$

$$\begin{cases} 2x_1 + x_2 + x_3 \leq 8 & (1) \end{cases}$$

$$\begin{cases} x_1 + x_2 + x_3 \geq 3 & (2) \end{cases}$$

$$\begin{cases} -3x_1 + x_2 + 2x_3 \leq -5 & (3) \end{cases}$$

$$\begin{cases} x_1 \geq 0, x_2 \geq 0, x_3 \text{ 无符号要求} \end{cases}$$

$$\text{Min } Z' = x_1 - x_2 + 3x'_3 - 3x''_3$$

$$\begin{cases} 2x_1 + x_2 + x'_3 - x''_3 + x_4 = 8 \end{cases}$$

$$\begin{cases} x_1 - x_2 + x'_3 - x''_3 - x_5 = 3 \end{cases}$$

$$\begin{cases} 3x_1 - x_2 - 2(x'_3 - x''_3) - x_6 = 5 \end{cases}$$

$$\begin{cases} x_1, x_2, x'_3, x''_3, x_4, x_5, x_6 \geq 0 \end{cases}$$



8、优化问题、线性规划、凸优化

8.2、线性规划标准型

【解】（1）因为 x_3 无符号要求，即 x_3 取正值也可取负值，标准型中要求变量非负，所以令

$$x_3 = x'_3 - x''_3, \text{其中 } x'_3, x''_3 \geq 0$$

(2) 第一个约束条件是 \leq 号，在 \leq 左端加入松弛变量 (slack variable) x_4 ， $x_4 \geq 0$ ，化为等式；

(3) 第二个约束条件是 \geq 号，在 \geq 号左端减去剩余变量 (Surplus variable) x_5 ， $x_5 \geq 0$ 。也称松弛变量

(4) 第三个约束条件是 \leq 号且常数项为负数，因此在 \leq 左边加入松弛变量 x_6 ， $x_6 \geq 0$ ，同时两边乘以 -1 。

(5) 目标函数是最大值，为了化为求最小值，令 $Z' = -Z$ ，得到 $\max Z' = -Z$ ，即当 Z 达到最大值时 Z' 达到最小值，反之亦然。

【例1-12】将下列线性规划化为标准型

$$\text{Max } Z = -x_1 + x_2 - 3x_3$$

$$\begin{cases} 2x_1 + x_2 + x_3 \leq 8 & (1) \end{cases}$$

$$\begin{cases} x_1 + x_2 + x_3 \geq 3 & (2) \end{cases}$$

$$\begin{cases} -3x_1 + x_2 + 2x_3 \leq -5 & (3) \end{cases}$$

$$\begin{cases} x_1 \geq 0, x_2 \geq 0, x_3 \text{ 无符号要求} \end{cases}$$



8、优化问题、线性规划、凸优化

8.3、对偶问题

线性规划的原问题与对偶问题

$$\begin{array}{ll} \text{Min} & Z = cX \\ (P) & \text{s.t.} \begin{cases} AX \geq b \\ X \geq 0 \end{cases} \\ \\ \text{max} & w = Yb \\ (D) & \text{s.t.} \begin{cases} YA \leq C \\ Y \geq 0 \end{cases} \end{array}$$

$$\begin{array}{ll} \min z = 8x_1 + 16x_2 + 12x_3 & \max w = 2y_1 + 3y_2 \\ \text{s.t.} \begin{cases} x_1 + 4x_2 \geq 2 \\ 2x_1 + 4x_3 \geq 3 \\ x_1, x_2, x_3 \geq 0 \end{cases} & \text{s.t.} \begin{cases} y_1 + 2y_2 \leq 8 \\ 4y_1 \leq 16 \\ 4y_2 \leq 12 \\ y_1, y_2 \geq 0 \end{cases} \end{array}$$

原问题（对偶问题）	对偶问题（原问题）
目标函数 $\min z$	目标函数 $\max w$
约束条件： m个 第i个约束类型为“ \leq ” 第i个约束类型为“ \geq ” 第i个约束类型为“ $=$ ”	变量数： m个 第i个变量 ≤ 0 第i个变量 ≥ 0 第i个变量是自由变量
变量数： n个 第j个变量 ≥ 0 第j个变量 ≤ 0 第j个变量是自由变量	约束条件： n个 第j个约束类型为“ \leq ” 第j个约束类型为“ \geq ” 第j个约束类型为“ $=$ ”
决策系数 c	右端项c
右端项b	决策系数b
约束矩阵的第j列	约束矩阵的第j行



8、优化问题、线性规划、凸优化

8.3、对偶理论

1.弱对偶定理:

若 X^0 是原问题(P)的可行解, Y^0 是对偶问题(D)的可行解, 则 $cX^0 \geq Y^0b$


表明:

(P) 的任一可行解对应目标函数值总是 (D) 目标函数值的上界,
(D) 的任一可行解对应目标函数值总是 (P) 目标函数值的下界.

2.强对偶定理:


若 X^0 , Y^0 分别是原问题(P)和对偶问题(D)的可行解,

且 $cX^0 = Y^0b$, 则 X^0 , Y^0 分别是原问题(P)和对偶问题(D)的最优解



(若 (P) 和 (D) 中有一个问题有最优解, 则另一个问题也有最优解,
且它们的目标函数值相等)

8、优化问题、线性规划、凸优化



8.4、凸优化问题

定义：一个凸优化问题是指

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i = 1, 2, \dots, s, \\ & h_j(x) = 0, \quad j = 1, 2, \dots, t. \end{array}$$

目标函数是凸函数，可行域是凸集。

（目标函数是凸函数，不等约束函数是凸函数，

等式约束函数是仿射函数）

性质：1、局部最优解是全局最优解

2、可微函数最优解的一个判别准则

当凸优化问题的目标函数 f 是可微的，有

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

判别准则：

x 是最优解 $\Leftrightarrow \nabla f(x)^T (y - x) \geq 0$, 对任意 $y \in X$ (可行域)

3、等式约束优化问题

$$\begin{array}{ll} \text{Min} & f(x) \\ \text{s.t.} & Ax = b. \end{array}$$

最优判别准则：

x 是最优解 $\Leftrightarrow \nabla f(x)^T (y - x) \geq 0$, 对任意 $y \in X$ (可行域)



感谢老师的悉心指导

THANK YOU!

汇报人 | XXX

指导老师 | XXX